




Thèse Projet ANR "Numalyse"

SBD Synthèse

Benjamin Serva

GitHub : https://github.com/bserva34/Numalyse_thesis

February 27, 2026

Encadrants :

Olivier Strauss & William Puech & Frédéric Comby

1 Méthodes

1.1 Classique

- Adaptive - implémenté dans PySceneDetect [1] : Calcule un score de variation entre images consécutives à partir des différences de couleur (HSV) et des contours (edges). Un lissage par moyenne glissante permet de réduire les faux positifs.
 - **Avantages** : Très bonne précision pour les transitions abruptes (cuts).
 - **Inconvénients** : Peu performant pour les transitions progressives longues (fondu, dissolve).
- Suguna et al. [2] : Analyse la différence d’histogrammes HSV entre images à l’aide d’une distance du khi-deux. La méthode fonctionne en double passe : détection de segments candidats puis validation des transitions potentielles.
 - **Avantages** : Méthode rapide et efficace pour les cuts.
 - **Inconvénients** : Sensible aux variations d’illumination et aux mouvements rapides ; précision limitée.

1.2 Géométrie

- Bi et al. [3] : Utilise la Dynamic Mode Decomposition (DMD) pour modéliser la dynamique du fond de la scène. Les ruptures dans cette dynamique indiquent une transition.
 - **Avantages** : Bonne détection des frontières des transitions abruptes et progressives ; robuste aux mouvements de caméra.
 - **Inconvénients** : Temps de calcul élevé.

1.3 Deep Learning

- Hassanien et al. [4] → DeeSBD : Réseau CNN spatio-temporel analysant une fenêtre de frames. Le modèle extrait des caractéristiques temporelles puis un classifieur prédit le type de transition.
 - **Avantages** : Haute précision ; classification des types de transitions.
 - **Inconvénients** : Dépend de la taille de la fenêtre (frontières moins précises) ; nécessite un large dataset annoté.
- Soucek et Lokoc [5] → TransNetV2 : Réseau CNN 3D optimisé pour la détection image par image. Le modèle produit une probabilité de transition pour chaque frame, ce qui permet une localisation plus fine.
 - **Avantages** : Très bon compromis précision/vitesse ; bonne généralisation ; localisation précise des cuts et dissolves.
 - **Inconvénients** : Moins robuste sur transitions très longues ou atypiques ; reste dépendant des données d’entraînement.
- Zhu et al. [6] → AutoShot : Extension de TransNetV2 combinant CNN spatio-temporel et Neural Architecture Search (NAS). Architecture optimisée automatiquement pour améliorer performance et efficacité, notamment sur vidéos courtes.
 - **Avantages** : Excellentes performances globales ; efficace sur transitions courtes ; modèle optimisé.
 - **Inconvénients** : Complexité d’entraînement élevée ; forte dépendance aux données.

1.4 Résultats Annoncé

Méthode	Dataset de Test	F1-Score
Adaptive [1]	BBC [7]/AutoShot [6]	67.84%
Suguna et al. [2]	TRECVID 2001	94.80%
Bi et al. [3]	TRECVID (?)	88.60%
Hassanien et al. [4] : DeeSBD	RAI [8]	94.00%
Souceck et Lokoc [5] : TransNetV2	BBC [7]/RAI [8]/ClipShots	89.33%
Zhu et al. [6] : AutoShot	BBC [7]/RAI [8]/ClipShots	90.43%

Table 1: Overview résultats annoncés méthodes SBD

2 Protocole Évaluation

- **Précision, Rappel et F1-Score (Strict)** : Une prédiction de transition est considérée comme un vrai positif si la valeur absolue de l'écart entre le début de la prédiction et le début de la vérité terrain est inférieure ou égale à la tolérance fixée, et si la même condition est vérifiée pour la fin de la prédiction et la fin de la vérité terrain. Soit un vrai positif est défini par :

$$(|p_{end} - g_{end}| \leq tolerance) \wedge (|p_{start} - g_{start}| \leq tolerance) == True \quad (1)$$

- **Précision, Rappel et F1-Score (Cool)** : Dans ce cas, la prédiction est considérée correcte si au moins l'une des deux conditions précédentes est vérifiée :

$$(|p_{end} - g_{end}| \leq tolerance) \vee (|p_{start} - g_{start}| \leq tolerance) == True \quad (2)$$

- **Coverage et Overflow** : Pour chaque transition de vérité terrain $g = [g_{start}, g_{end}]$, on recherche la prédiction $p = [p_{start}, p_{end}]$ maximisant l'intersection temporelle.

On définit d'abord :

$$Intersection(p, g) = \max(0, \min(p_{end}, g_{end}) - \max(p_{start}, g_{start}) + 1) \quad (3)$$

La longueur d'une transition est définie par :

$$|g| = g_{end} - g_{start} + 1 \quad (4)$$

Coverage pour une transition g_i est alors :

$$Coverage_i = \max_{p_j} \frac{Intersection(p_j, g_i)}{|g_i|} \quad (5)$$

Overflow mesure l'excès de prédiction en dehors de la vérité terrain. Pour la prédiction p_{best} maximisant l'intersection :

$$Overflow_i = \frac{|p_{best}| - Intersection(p_{best}, g_i)}{|g_i|} \quad (6)$$

avec :

$$|p_{best}| = p_{end} - p_{start} + 1 \quad (7)$$

- **Intersection over Union (IoU)** combine naturellement le Coverage et l'Overflow :

$$IoU_i = \frac{Coverage_i}{1 + Overflow_i} \quad (8)$$

3 Datasets d'évaluation

3.1 Contexte

Notre cas d'application est le cinéma. Or, dans certaines périodes du cinéma, les transitions progressives durant plusieurs secondes sont largement répandues. Des datasets annotés respectant de telles contraintes n'existent tout simplement pas. C'est pour cela que j'ai dû m'intéresser à la génération de transitions.

3.2 Génération de transitions

Pour l'instant, je me suis contenté de générer seulement deux types de transitions (celles les plus répandues dans le cinéma avec les cuts) : le fondu enchaîné et le fondu au noir.

Pour le fondu au noir, il y a deux sous-classes : miroir, c'est-à-dire qu'il y a une symétrie par rapport à la transition de base, et non miroir, où aucune symétrie n'est respectée.

La longueur des transitions générées est aléatoire et respecte l'intervalle de frames suivant : $[30, 250]$ (en sachant que le maximum peut être réduit en fonction de la longueur du plan).

Un exemple de chaque type de transition est illustré dans la Figure 1.

3.3 Extension de BBC

Pour faire cela, je me suis appuyé sur le dataset BBC [7], qui est un dataset largement connu pour la problématique du SBD. Il est annoté et contient principalement des cuts, ainsi que des transitions progressives ne durant que quelques frames.


À partir de ce dataset, j'ai généré trois nouveaux datasets :

1. **BBC 2** : une évolution du dataset BBC avec des fondus enchaînés.
2. **BBC 3** : une évolution du dataset BBC avec des fondus au noir miroir.
3. **BBC 4** : une évolution du dataset BBC avec des fondus au noir non miroir.


Les distributions des transitions dans chaque dataset sont représentées dans la Figure 4.

Pour la suite, nous considérons trois datasets :

1. **BBC Cut**, qui correspond au BBC original ;
2. **BBC Dissolve**, qui est la combinaison des BBC 2, 3 et 4 ;
3. **BBC Global**, qui contient les quatre datasets.



Distribution pour le dataset BBC 4




Distribution pour les datasets BBC 2 et 3

Figure 2: Distribution des longueurs de transitions




Vidéo de base



fendu au noir miroir



fendu noir non miroir



fendu enchainée

Figure 1: Exemple de génération

4 Expérimentation et résultats

Afin d'évaluer de manière pertinente chaque méthode, j'ai réalisé une évaluation avec une tolérance variant de 0 à 12. Grâce à ces expérimentations, j'ai pu observer qu'à partir d'une tolérance de 6, l'ensemble des valeurs pour chaque méthode converge. Ainsi, pour les résultats présentés dans les tableaux, je fixe une tolérance à 6.

4.1 BBC Cut

Algo	Coverage	Overflow ↓	IoU	P	R	F1-S
Adaptive [1]	0.8724	0.0011	0.8720	97.55%	87.80%	<u>92.42%</u>
Suguna et al. [2]	0.5105	1.1768	0.3211	74.85%	94.17%	83.39%
Bi et al. [3]	0.1300	0.3938	0.0561	59.38%	52.39%	55.67%
Bi et al. fenetre [3]	0.1156	0.2444	0.0581	78.20%	61.60%	68.91%
Hassanien et al. [4] : DeeSBD	0.4195	1.6866	0.0878	94.47%	41.99%	58.14%
Soucek et Lokoc [5] : TransNetV2	0.8463	0.0489	0.8303	94.68%	89.00%	91.75%
Zhu et al. [6] : AutoShot	<u>0.8719</u>	<u>0.0446</u>	0.8570	<u>97.09%</u>	<u>92.28%</u>	94.62%

Table 2: Résultat pour BBC Cut (STRICT et tolérance = 6)

4.2 BBC Dissolve




Figure 3: BBC Dissolve

Algo	Coverage	Overflow ↓	IoU	P	R	F1-S
Adaptive [1]	0.1463	0.0002	0.1463	30.71%	14.45%	19.66%
Suguna et al. [2]	<u>0.2416</u>	0.3545	0.1990	10.46%	<u>16.71%</u>	12.87%
Bi et al. [3]	0.0198	0.0435	0.0117	13.36%	05.13%	07.42%
Bi et al. fenetre [3]	0.0258	0.0230	0.0201	08.02%	06.09%	06.92%
Hassanien et al. [4] : DeeSBD	0.0747	0.2384	0.0272	39.84%	06.06%	10.52%
Soucek et Lokoc [5] : TransNetV2	0.3672	0.0013	0.3665	14.06%	18.90%	16.12%
Zhu et al. [6] : AutoShot	0.1589	<u>0.0006</u>	0.1587	25.66%	14.81%	<u>18.78%</u>

Table 3: Résultat pour BBC Dissolve (STRICT et tolérance = 6)

4.3 BBC Global




Figure 4: BBC Global

Algo	Coverage	Overflow ↓	IoU	P	R	F1-S
Adaptive [1]	0.3279	0.0004	0.3277	56.75%	32.80%	41.58%
Suguna et al. [2]	0.3088	0.5601	0.2296	23.85%	<u>36.08%</u>	28.72%
Bi et al. [3]	0.0473	0.1311	0.0228	33.33%	16.96%	22.48%
Bi et al. fenetre [3]	0.0483	0.0784	0.0296	26.06%	19.98%	22.62%
Hassanien et al. [4] : DeeSBD	0.1609	0.6005	0.0424	66.80%	15.05%	24.57%
Soucek et Lokoc [5] : TransNetV2	0.4870	0.0132	0.4824	29.31%	36.44%	32.49%
Zhu et al. [6] : AutoShot	<u>0.3422</u>	<u>0.0117</u>	0.3383	46.87%	34.42%	<u>39.69%</u>

Table 4: Résultat pour BBC Global (STRICT et tolérance = 6)

5 Analyse/Bilan

- **Approches classiques :** Bonnes performances sur BBC Cut, mais effondrement marqué du rappel sur BBC Dissolve. Il est difficile de trouver un compromis optimal entre précision et rappel permettant de détecter simultanément les cuts et les transitions progressives, sans devenir trop sensible aux variations locales (mouvements de caméra, variations d'illumination).

L'ajout de nouvelles caractéristiques (texture, gradients, information fréquentielle, etc.) augmenterait probablement le coût computationnel, sans garantie d'amélioration significative des performances sur les transitions longues.

Ces méthodes pourraient toutefois être utilisées avec un seuil très strict afin de détecter uniquement les cuts dans un film. Les transitions progressives pourraient alors être générées artificiellement ou détectées dans un second temps par une autre méthode plus adaptée. Ceci pour la conception d'un dataset cinéma d'entraînement pour le deep learning.

- **Approche géométrique (DMD) :** Inutilisable en l'état actuel comme détecteur principal. La caractéristique dynamique extraite est théoriquement robuste, notamment aux mouvements de caméra, mais la détermination d'un seuil reste complexe.

En revanche, la DMD semble pertinente comme outil d'affinage : elle pourrait permettre d'approximer plus précisément les frontières d'une transition déjà détectée grossièrement par une autre méthode.

- **Approches Deep Learning :**

AutoShot présente de bonnes performances globales, mais son optimisation pour des vidéos courtes et des transitions brèves limite sa capacité à généraliser aux transitions longues typiques du cinéma.

DeepSBD obtient des résultats faibles dans nos expérimentations. Toutefois, ces performances doivent être interprétées avec prudence, le modèle ayant été entraîné sur un dataset relativement restreint. On observe malgré tout une précision élevée sur l'ensemble des tests, indiquant une forte capacité de discrimination, mais un rappel insuffisant.

Enfin, TransNetV2 se démarque nettement. Il présente un coverage élevé et un overflow très faible, traduisant une bonne localisation temporelle des transitions. De plus, son F1-Score (Cool) sur les transitions progressives est significativement supérieur aux autres méthodes, ce qui confirme sa capacité à détecter des transitions étalées dans le temps. Il constitue ainsi la base la plus robuste pour une adaptation au domaine du cinéma.

6 Perspectives de Méthodes

1. **Fine-tuning de TransNetV2 sur un dataset cinéma.** Adapter le modèle aux transitions longues en l'entraînant sur BBC Global et sur des transitions générées plus réalistes. L'objectif est d'apprendre explicitement la distribution temporelle des fondus longs.
2. **Extension temporelle du modèle.** Renforcer TransNetV2 par :
 - une convolution dilatée afin d'augmenter le champ réceptif temporel,
 - ou un module Transformer temporel léger pour capturer des dépendances à longue portée (jusqu'à 300 frames).

Cela permettrait de mieux modéliser les transitions progressives longues typiques du cinéma classique.

3. **Affinage des frontières par DMD.** Utiliser la Dynamic Mode Decomposition non comme détecteur principal, mais comme mécanisme de raffinement des frontières temporelles prédites par le modèle deep learning. La DMD pourrait permettre d'identifier plus précisément les points de rupture dynamique à l'intérieur d'une zone de transition détectée.

Dans le cas où l'utilisation du deep learning ne serait pas possible, une approche en deux passes pourrait être envisagée :

1. Première passe : utilisation d'une méthode classique réglée pour maximiser le rappel (détection large de candidats transitions).
2. Seconde passe : validation et affinage des segments candidats via une analyse dynamique (DMD), permettant de réduire les faux positifs et d'améliorer la localisation.

Cette approche permettrait de combiner simplicité computationnelle et robustesse dynamique.

References

- [1] P. D. P. Library, “Scenedetect — video shot cut/transition detection,” 2025. [Online]. Available: <https://www.scenedetect.com>
- [2] R. S. M., K. A., and A. S., “The detection of video shot transitions based on primary segments using the adaptive threshold of colour-based histogram differences and candidate segments using the surf feature descriptor,” *Symmetry*, vol. 14, no. 10, 2022. [Online]. Available: <https://www.mdpi.com/2073-8994/14/10/2041>
- [3] C. Bi, Y. Yuan, J. Zhang, Y. Shi, Y. Xiang, Y. Wang, and R. Zhang, “Dynamic mode decomposition based video shot detection,” *IEEE Access*, vol. 6, pp. 21 397–21 407, 2018.
- [4] A. Hassanien, M. Elgharib, A. Selim, S.-H. Bae, M. Hefeeda, and W. Matusik, “Large-scale, fast and accurate shot boundary detection through spatio-temporal convolutional neural networks,” 2017. [Online]. Available: <https://arxiv.org/abs/1705.03281>
- [5] T. Soucek and J. Lokoc, “Transnet v2: An effective deep network architecture for fast shot transition detection,” in *Proceedings of the 32nd ACM International Conference on Multimedia*, ser. MM ’24. New York, NY, USA: Association for Computing Machinery, 2024, p. 11218–11221. [Online]. Available: <https://doi.org/10.1145/3664647.3685517>
- [6] W. Zhu, Y. Huang, X. Xie, W. Liu, J. Deng, D. Zhang, Z. Wang, and J. Liu, “Autoshot: A short video dataset and state-of-the-art shot boundary detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2023.
- [7] L. Baraldi, C. Grana, and R. Cucchiara, “A deep siamese network for scene detection in broadcast videos,” in *Proceedings of the 23rd ACM International Conference on Multimedia*, ser. MM ’15. New York, NY, USA: Association for Computing Machinery, 2015, p. 1199–1202. [Online]. Available: <https://doi.org/10.1145/2733373.2806316>
- [8] —, “Shot and scene detection via hierarchical clustering for re-using broadcast video,” vol. 9256, 09 2015.